



1. El cuestionario anterior puso a prueba nuestro conocimiento de la regresión lineal y cómo podemos comenzar a modelar conjuntos de datos. En el último video, desarrollamos más esta idea, analizando el caso de los datos que no pueden modelarse de manera efectiva mediante aproximaciones lineales. Como tal, conocimos el método de mínimos cuadrados no lineales, como una forma de ajustar curvas no lineales a los datos.

1 / 1 punto

En esta pregunta, tenemos un conjunto de gráficos que destacan diferentes distribuciones de datos. Seleccione los gráficos apropiados en los que se pueda adaptar el método de mínimos cuadrados no lineales para proporcionar un ajuste efectivo a estos datos.


☒ Opción A**Correcto**

El método de mínimos cuadrados no lineales es muy similar al método de regresión lineal destacado anteriormente. Como tal, también hace un buen trabajo al ajustarse a curvas lineales, aunque este procesamiento adicional puede parecer innecesario en la mayoría de los casos.

☒ Opción B**Correcto**

Estos datos se parecen a una función exponencial y deberían poder ajustarse mediante la técnica de regresión no lineal.


☒ Opción C




Correcto

Estos datos se parecen a un gaussiano y deberían poder ajustarse mediante la técnica de regresión no lineal.

☐ Opción D



☒ Opción E



Correcto

Estos datos se parecen a la relación $\ln(x)$ y deberían poder ajustarse mediante la técnica de regresión no lineal.

2. En la conferencia anterior, se le llevó a través del ejemplo de h^2 y cómo es importante utilizar la suma de las diferencias y el método de los mínimos cuadrados. También nos presentaron la expresión

$$h^2 = \sum_{y_0=1}^{norte} \frac{[y_i - y(x_i; a_k)]^2}{pag^2}$$
. Para el parámetro h^2 , seleccione todas las declaraciones a continuación que sean verdaderas.

- ☐ El parámetro h^2 es el valor de incertidumbre de nuestras variables.
- ☐ Cuando h^2 es grande, tenemos un buen ajuste a nuestros datos.
- ☒ Tomando el gradiente de h^2 y establecer esto en cero nos permite determinar parámetros de ajuste efectivos.

✓ **Correcto**

Al encontrar el gradiente, estamos encontrando el mínimo de h^2 . Esto debería permitirnos construir un conjunto de ecuaciones simultáneas que luego se pueden analizar para ajustar de manera efectiva los parámetros a través del descenso más pronunciado.

- ☒ El parámetro h se eleva al cuadrado para minimizar el efecto de las malas incertidumbres.

✓ **Correcto**

Al calcular h , dividimos por el valor de incertidumbre pag . Como resultado, h se eleva al cuadrado para minimizar el efecto de dividir por un resultado altamente incierto.

3. En la lección anterior, tomamos la derivada de h^2 con respecto a nuestros parámetros de ajuste, cuya forma se muestra a continuación.

1 / 1 punto

$$\frac{\partial \chi^2}{\partial a_j} = -2 \sum_{y_0=1}^{\text{norte}} \frac{y_i - f(x_i, \mathbf{un})}{\text{pag}_i^2} \frac{\partial f(x_i, \mathbf{un})}{\partial a_j} \text{ para } j = 1 \dots \text{norte}$$

Aquí definiremos la matriz $[Z_j] = \frac{\partial f(x_i, \mathbf{un})}{\partial a_j}$

Asumiendo $f(x_i, \mathbf{un}) = a_1 X^3 - a_2 X^2 + y^{-un_3 X}$, seleccione la opción que muestra correctamente la diferenciación parcial para esta función.

- ☐ $\frac{\partial f}{\partial a_1} = X^3 - a_2 X^2 + y^{-un_3 X}, \frac{\partial f}{\partial a_2} = a_1 X^3 - X^2 + y^{-un_3 X}, \frac{\partial f}{\partial a_3} = a_1 X^3 - a_2 X^2 - x \ln^{-un_3 X}$
- ☒ $\frac{\partial f}{\partial a_1} = X^3, \frac{\partial f}{\partial a_2} = -X^2, \frac{\partial f}{\partial a_3} = -X \ln^{-un_3 X}$
- ☐ $\frac{\partial f}{\partial a_1} = 3 \ln_0 X^2, \frac{\partial f}{\partial a_2} = -2a_{-2} X, \frac{\partial f}{\partial a_3} = -\ln_3 y^{-un_3 X}$
- ☐ $\frac{\partial f}{\partial a_1} = X^3, \frac{\partial f}{\partial a_2} = 2X^{-2}, \frac{\partial f}{\partial a_3} = X \ln^{a_3 X}$

☒ **Correcto**

Aquí estamos diferenciando nuestra función de ajuste contra los parámetros de ajuste. Este es el primer paso para formar el jacobiano.

4. En esta pregunta, queremos poner nuestro conocimiento práctico de la diferenciación parcial de nuestras funciones y organizar esto en el jacobiano. Como recordatorio, el jacobiano para el método de mínimos cuadrados no lineales tomará la forma: $\mathbf{j} = \left[\frac{\partial (X^2)}{\partial a_k} \right] = \left[\frac{\partial (X^2)}{\partial a_1}, \frac{\partial (X^2)}{\partial a_2} \right]$.

para la ecuación $y(x_i; \mathbf{a}) = a_1(1 - y^{-un_2 X_i^2})$ y suponiendo $\sigma^2 = 1$, seleccione el jacobiano correcto que debe evaluarse para nuestra función de ajuste.

☐
$$\frac{\partial (X^2)}{\partial a_1} = -2 \sum_{\substack{\text{norte} \\ y_0 = 1}} [y_i - a_1(1 - y^{-un_2 X_i^2})] (y^{-un_2 X_i^2})$$

$$\frac{\partial (X^2)}{\partial a_2} = -2 \sum_{y_0 = 1} [y_i - a_1(1 - y^{-un_2 X_i^2})] (un_1 X_i^2 y^{-un_2 X_i^2})$$

☒
$$\frac{\partial (X^2)}{\partial a_1} = -2 \sum_{\substack{\text{norte} \\ y_0 = 1}} [y_i - a_1(1 - y^{-un_2 X_i^2})] (1 - y^{-un_2 X_i^2})$$

$$\frac{\partial (X^2)}{\partial a_2} = -2 \sum_{y_0 = 1} [y_i - a_1(1 - y^{-un_2 X_i^2})] (un_1 X_i^2 y^{-un_2 X_i^2})$$

☐
$$\frac{\partial (X^2)}{\partial a_1} = -2 \sum_{\substack{\text{norte} \\ y_0 = 1}} [y_i - a_1(1 - y^{-un_2 X_i^2})] (1 - y^{-un_2 X_i^2})$$

$$\frac{\partial (X^2)}{\partial a_2} = -2 \sum_{y_0 = 1} [y_i - a_1(1 - y^{-un_2 X_i^2})] (-X_i^2 y^{-un_2 X_i^2})$$

☐
$$\frac{\partial (X^2)}{\partial a_1} = -2 \sum_{\substack{\text{norte} \\ y_0 = 1}} [y_i - a_1(1 - y^{-un_2 X_i^2})] (1 + y^{-un_2 X_i^2})$$

$$\frac{\partial (X^2)}{\partial a_2} = -2 \sum_{y_0 = 1} [y_i - a_1(1 - y^{-un_2 X_i^2})] (un_1 X_i y^{-un_2 X_i^2})$$



Con el jacobiano, podemos realizar efectivamente nuestro método de descenso más empinado. Su forma también permite la facilidad de uso en el uso de métodos computacionales para evaluar esto.

5. En esta pregunta, desarrollaremos nuestra idea de construir más el jacobiano observando una función con parámetros más ajustados. La siguiente función es de una distribución gaussiana con 4 parámetros de ajuste(μ , σ , μ , σ) que se utilizarán en el método de mínimos cuadrados no lineales.

$$y(x; \mu, \sigma, \mu, \sigma) = b + \frac{y_0}{\sigma \sqrt{2\pi}} \exp \left\{ -\frac{(x - \mu)^2}{2\sigma^2} \right\}$$

En las conferencias, también mostramos cómo encontrar $\frac{\partial y}{\partial \mu}$ y cómo esto forma el jacobiano que se muestra a continuación:

$$\mathbf{j} = \left[\frac{\partial y}{\partial \mu} \right] = \left[\frac{\partial y}{\partial \mu}, \frac{\partial y}{\partial \sigma}, \frac{\partial y}{\partial \mu}, \frac{\partial y}{\partial \sigma} \right].$$

donde

$$\frac{\partial^2 y}{\partial \mu^2} = -2 \sum_{i=1}^n \frac{y_i - y(x_i; \mu, \sigma)}{\sigma^2} \frac{\partial y(x_i; \mu, \sigma)}{\partial \mu} \text{ para } j = 1, \dots, n$$

Para la función gaussiana anterior, determine la diferencial parcial

$$\frac{\partial y}{\partial \mu}$$

- ☐ $\frac{\partial y}{\partial \mu} = \frac{y_0}{\sigma \sqrt{2\pi}} \frac{2x - \mu}{\sigma^2} \exp \left\{ -\frac{(x - \mu)^2}{2\sigma^2} \right\}$
- ☒ $\frac{\partial y}{\partial \mu} = \frac{y_0}{\sigma \sqrt{2\pi}} \frac{(x - \mu)}{\sigma^3} \exp \left\{ -\frac{(x - \mu)^2}{2\sigma^2} \right\}$
- ☐ $\frac{\partial y}{\partial \mu} = -\frac{y_0}{\sigma \sqrt{2\pi}} \frac{(x - \mu)}{2\sigma^3} \exp \left\{ -\frac{(x - \mu)^2}{2\sigma^2} \right\}$
- ☐ $\frac{\partial y}{\partial \mu} = \frac{y_0}{\sigma \sqrt{2\pi}} \frac{2(x - \mu)}{\sigma^2} \exp \left\{ -\frac{(x - \mu)^2}{2\sigma^2} \right\}$

✓ **Correcto**

Aquí solo estamos evaluando una derivada parcial que forma parte del jacobiano. Para ajustar correctamente la Gaussiana a un conjunto específico de datos, necesitaremos evaluar todas las derivadas parciales mencionadas anteriormente.